온라인 쇼핑 세션 구매 확률 예측 모델 보고서

온라인 쇼핑 세션 구매 확률 예측 모델 보고서

(UCI Online Shoppers Purchasing Intention Dataset 기반)

---

0. 요약 (Executive Summary)

- **목적**
  - 온라인 쇼핑 웹사이트의 세션 단위로, **해당 방문에서 실제 구매(Revenue=1)가 발생할 확률**을 예측하는 모델을 구축하였다.
  - 단순 모델 성능을 넘어서, **마케팅·기획·운영 팀이 실무에서 바로 활용 가능한 형태**의 예측 도구와 데모 애플리케이션을 제공하는 것을 목표로 했다.
- **데이터**
  - UCI Online Shoppers Purchasing Intention Dataset 사용
  - 세션 단위 데이터이며, 행동(log) 정보 + 세션 특성 + 방문자 특성을 포함
  - 타깃 변수: `Revenue` (0=미구매, 1=구매)
  - 구매(1) 비율이 낮은 **불균형 데이터**임
- **모델링 접근**
  - 불균형 데이터에 강한 **Balanced Random Forest**를 핵심 알고리즘으로 선정
  - 전처리(수치형 RobustScaler, 범주형 OneHotEncoder)와 분류기를 `Pipeline`으로 통합
  - **예측값을 '확률'로 해석 가능한 형태로 만들기 위해, Calibration(확률 보정) 단계**를 추가
    - `train`으로 base 모델 학습 → `calib`으로 확률 보정 → `test`로 최종 성능 확인
  - 모델 목적에 따라 **두 개의 최종 모델**을 별도로 튜닝 및 저장
    - **PR-AUC 최적화 모델:** `best_pr_auc_balancedrf.joblib`
    - **F1 Score 최적화 모델:** `best_balancedrf_pipeline.joblib` (+ threshold 내장)

- **주요 성능**
  - PR-AUC 최적화 모델
    - Best CV PR-AUC: **0.756**
    - Test PR-AUC: **0.747**
    - Test ROC-AUC: **0.930**
  - F1 최적화 모델
    - OOF F1: **0.700**
    - Test F1: **0.674**
    - Test PR-AUC: **0.742**
    - Test ROC-AUC: **0.932**
    - Best threshold: **0.741**
- **서빙 및 활용**
  - `PurchaseModelAdapter` + `SessionProbabilityService` 레이어를 통해 모델 교체/확장에 유연한 구조를 구성
  - Streamlit 앱에서 사용자에게 **"구매 확률(%)"**을 제공하기 위해, 모델 출력값을 그대로 사용하지 않고 **보정된 확률(calibrated proba)** 을 사용하도록 구성
  - Streamlit 앱 2종 구현
    - 세션 구매 확률 계산기 (실제 세션 입력)
    - 가상 고객 페르소나 생성기 (시나리오 기반 세션 자동 생성)

---

1. 프로젝트 개요

1.1 목적

본 프로젝트의 목적은 **온라인 쇼핑 세션 단위로 해당 방문에서 구매가 발생할지 (Revenue=1)를 예측하는 머신러닝 모델**을 구축하는 것이다.

단순히 정확한 예측값을 산출하는 것에서 나아가, 다음을 목표로 한다.

- 마케팅, 기획, 운영 담당자가 이해하기 쉬운 **"구매 확률"** 형태로 제공

  (단, 확률의 신뢰도를 높이기 위해 모델 출력 확률에 대해 **Calibration(확률 보정)** 을 적용)
- 예측 결과에 기반해 **쿠폰 발송, 리타깃팅, 이탈 방지 액션** 등 실제 의사결정에 활용 가능

- 데모/교육용으로도 사용 가능한 **인터랙티브 앱** 제공

1.2 사용 데이터

- 데이터셋: **UCI Online Shoppers Purchasing Intention Dataset**
- 단위: 1행 = 1 세션(session)
- 타깃 변수: `Revenue` (0 = 미구매, 1 = 구매)

주요 feature 그룹은 다음과 같다.

- **행동 지표**
  - `Administrative`, `Informational`, `ProductRelated`
  - `Administrative_Duration`, `Informational_Duration`, `ProductRelated_Duration`
    → 어떤 유형의 페이지를 얼마나 많이, 얼마나 오래 봤는지
- **세션 품질**
  - `BounceRates`, `ExitRates`, `PageValues`, `SpecialDay`
    → 이탈 정도, 페이지의 금전적 가치, 특수일 여부 등
- **고객/세션 속성**
  - `Month`, `OperatingSystems`, `Browser`, `Region`
  - `TrafficType`, `VisitorType`, `Weekend`

데이터는 실제 이커머스 환경과 마찬가지로, **구매(Revenue=1) 비율이 매우 낮은 불균형 데이터**이다.

따라서 본 프로젝트에서는 **불균형 데이터에 적합한 알고리즘 + 적절한 평가 지표 선택**을 핵심 이슈로 삼았다.

---

2. 모델링 접근 개요

2.1 알고리즘 선택: Balanced Random Forest

여러 분류 모델 후보를 검토한 끝에, 본 프로젝트에서는 **Balanced Random Forest(BRF)**를 핵심 알고리즘으로 채택하였다.

- **불균형 데이터 대응**
  - 일반 Random Forest는 다수 클래스(미구매)에 편향될 위험이 있음
  - Balanced Random Forest는 각 트리 학습 시 **클래스별 샘플 수를 균형 있게 맞추는 방식**으로

소수 클래스(구매)의 패턴을 학습에 충분히 반영

- **설명 가능성(Explainability)**
  - 트리 기반 모델이라 feature importance, 분기 규칙 등을 통해 “어떤 행동/특징이 구매에 영향을 미쳤는지”를 설명하기 상대적으로 쉽다.
- **성능과 실용성의 균형**
  - ROC-AUC, PR-AUC 등 주요 지표에서 높은 성능
  - 예측 속도 또한 실무 환경에서 충분히 빠른 수준

2.2 전처리 및 파이프라인 구성

모델링은 전처리와 분류기를 하나의 파이프라인으로 묶어 수행하였다.

- **컬럼 분리**
  - 수치형: `num_cols = X_train.select_dtypes(include=["number"]).columns`
  - 범주형: `cat_cols = X_train.select_dtypes(include=["object", "bool", "category"]).columns`
- **전처리**
  - 수치형(`num_cols`): `RobustScaler` 적용
    → 이상치에 덜 민감한 스케일링
  - 범주형(`cat_cols`): `OneHotEncoder(handle_unknown="ignore")` 적용
    → 학습 시 없던 새로운 카테고리도 테스트 시 에러 없이 처리
- **파이프라인 구성**

```
preprocess = ColumnTransformer(
    transformers=[
        ("num", RobustScaler(), num_cols),
        ("cat", OneHotEncoder(handle_unknown="ignore"), cat_cols),
    ],
    remainder="drop",
)

base = BalancedRandomForestClassifier(
    n_jobs=-1,
    random_state=RANDOM_STATE
)
```

```
pipe = Pipeline([
    ("preprocess", preprocess),
    ("model", base),
])
```

이 파이프라인을 기반으로, 각각 **PR-AUC 최적화**와 **F1 최적화**를 위한 하이퍼파라미터 탐색을 진행했다.

2.3 확률 보정(Calibration) 적용

본 프로젝트는 예측 결과를 단순한 "분류 결과(구매/미구매)"가 아니라, 마케팅/운영 실무에서 바로 활용 가능한 **"구매 확률(%)"** 형태로 제공하는 것을 목표로 한다.

그러나 Balanced Random Forest(BRF)는 학습 과정에서 각 트리마다 다수 클래스(미구매)를 언더샘플링하여 클래스 비율을 인위적으로 균형에 가깝게 맞추는 특성이 있다.
이로 인해 `predict_proba()` 출력값이 **현실 데이터 분포에서의 확률**로 바로 해석되기 어려운 문제가 발생할 수 있다.

따라서 본 프로젝트에서는 모델 출력 확률을 실무적으로 해석 가능한 형태로 만들기 위해 **Calibration(확률 보정)** 단계를 추가하였다.

- **Base 모델 학습(train)**
  - 전처리 + BRF 파이프라인을 `train.csv`로 학습
- **확률 보정(calib)**
  - 별도로 분리한 `calib.csv`를 이용해 `CalibratedClassifierCV`로 확률 보정
  - 방법: `sigmoid(Platt scaling)`을 기본 적용(데이터 크기 대비 안정성이 높음)
- **최종 검증(test)**
  - `test.csv`로 PR-AUC/ROC-AUC 등 성능을 최종 sanity check

이 과정을 통해 모델 출력값을 "확률처럼 보이는 점수"가 아니라,
실제 의사결정에 사용할 수 있는 '보정된 확률' 로 제공하도록 설계하였다.

---

3. 평가 지표 설계

3.1 핵심 지표

본 프로젝트에서 사용한 주요 평가지표는 다음과 같다.

1. **ROC-AUC**
   - 참양성률(TPR)과 거짓양성률(FPR)의 관계를 통합적으로 측정

- 전체 구간에서 분류기의 전반적인 성능을 평가하는 전통적인 지표

2. **PR-AUC (Average Precision)**
   - Precision–Recall 곡선 아래의 면적
   - **양성 클래스 비율이 낮을 때,** "모델이 양성이라고 예측한 샘플 중 실제 양성 비율"을 잘 반영

   → "예측 확률이 높은 사람일수록 진짜로 구매자일 확률이 높다"라는 **정렬 능력**을 평가하는 지표(threshold-free 지표)
   - 본 데이터처럼 구매(1)가 적은 경우 매우 중요한 지표
3. **F1 Score**
   - Precision과 Recall의 조화 평균
   - 특정 threshold에서 **양성/음성 오분류의 균형**을 실제로 보는 지표
   - 실제 운영에서는 threshold 선택까지 포함한 모델이 중요함

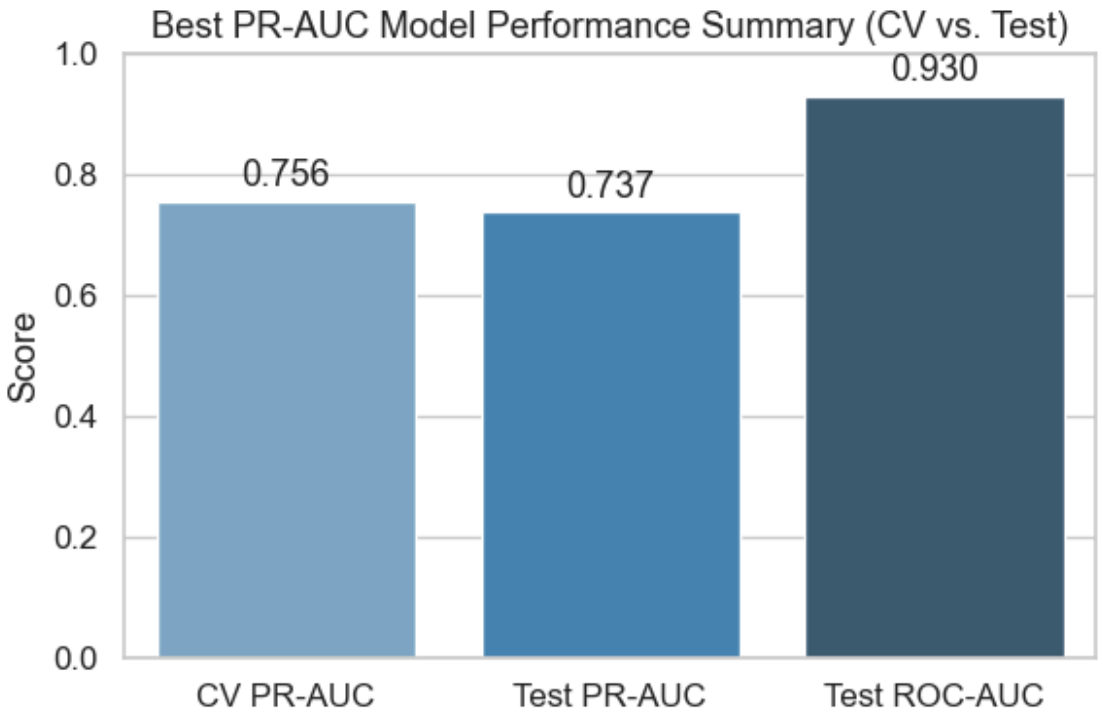

[그림 3-1] PR-AUC 최적화 모델의 교차검증(CV) PR-AUC와 테스트(Test) PR-AUC/ROC-AUC 막대그래프

3.2 모델 선정 전략

- **PR-AUC 최적화 모델**
  - "구매 고객을 놓치지 않고 잘 잡아내는 모델"에 초점

    - **확률 분포 / 순위**가 좋아지는 방향으로만 모델을 튜닝
    - 타깃팅/분석/시뮬레이션용 기준 모델로 활용
- **F1 최적화 모델**
    - Out-of-Fold 예측을 활용하여 F1이 최대가 되는 threshold를 찾고, 그 threshold를 기준으로 Test 성능을 평가
    - Balanced RF 하이퍼파라미터 여러 조합

      → 각 조합마다 OOF 예측으로 **threshold를 움직여가며 F1이 최대인 지점을 탐색**
    - threshold까지 함께 튜닝한 뒤, **실제 운영에 바로 적용 가능한 형태**로 사용

PR-AUC 모델은 **점수/순위용이라 threshold를 유연하게 두고**, F1 모델은 **실제 0/1 의사결정에 바로 쓸 수 있게 threshold까지 포함한 '완성된 룰'로 제작,** 결과적으로, **서로 다른 목적을 가진 모델 2개**를 별도로 튜닝하고, 각각 `best_pr_auc_balancedrf.joblib`, `best_balancedrf_pipeline.joblib`로 저장하였다.

추가적으로, 본 프로젝트는 예측값을 확률로 활용하는 목적이 있으므로 PR-AUC/ROC-AUC 같은 분류 성능 지표 외에도, 모델 출력 확률의 해석 가능성을 높이기 위해 **Calibration(확률 보정)** 절차를 포함하였다.
(예: '0.7'로 예측된 집단이 실제로도 70% 수준인지에 대한 신뢰도 개선)

---

4. PR-AUC 기반 하이퍼파라미터 탐색

4.1 탐색 설정

PR-AUC 최적화를 위해 `RandomizedSearchCV`를 사용했고, 탐색 공간은 다음과 같다.

- `model__n_estimators`: [300, 500, 800, 1200]
- `model__max_depth`: [None, 8, 12, 16, 20]
- `model__min_samples_leaf`: [1, 2, 4, 8, 12]
- `model__min_samples_split`: [2, 5, 10]
- `model__max_features`: ["sqrt", 0.3, 0.5, 0.8]
- `model__sampling_strategy`: ["auto", 0.5, 0.7, 1.0]
- `model__replacement`: [False, True]
- 교차검증: `StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`
- 스코어: `scoring = "average_precision"` (PR-AUC)

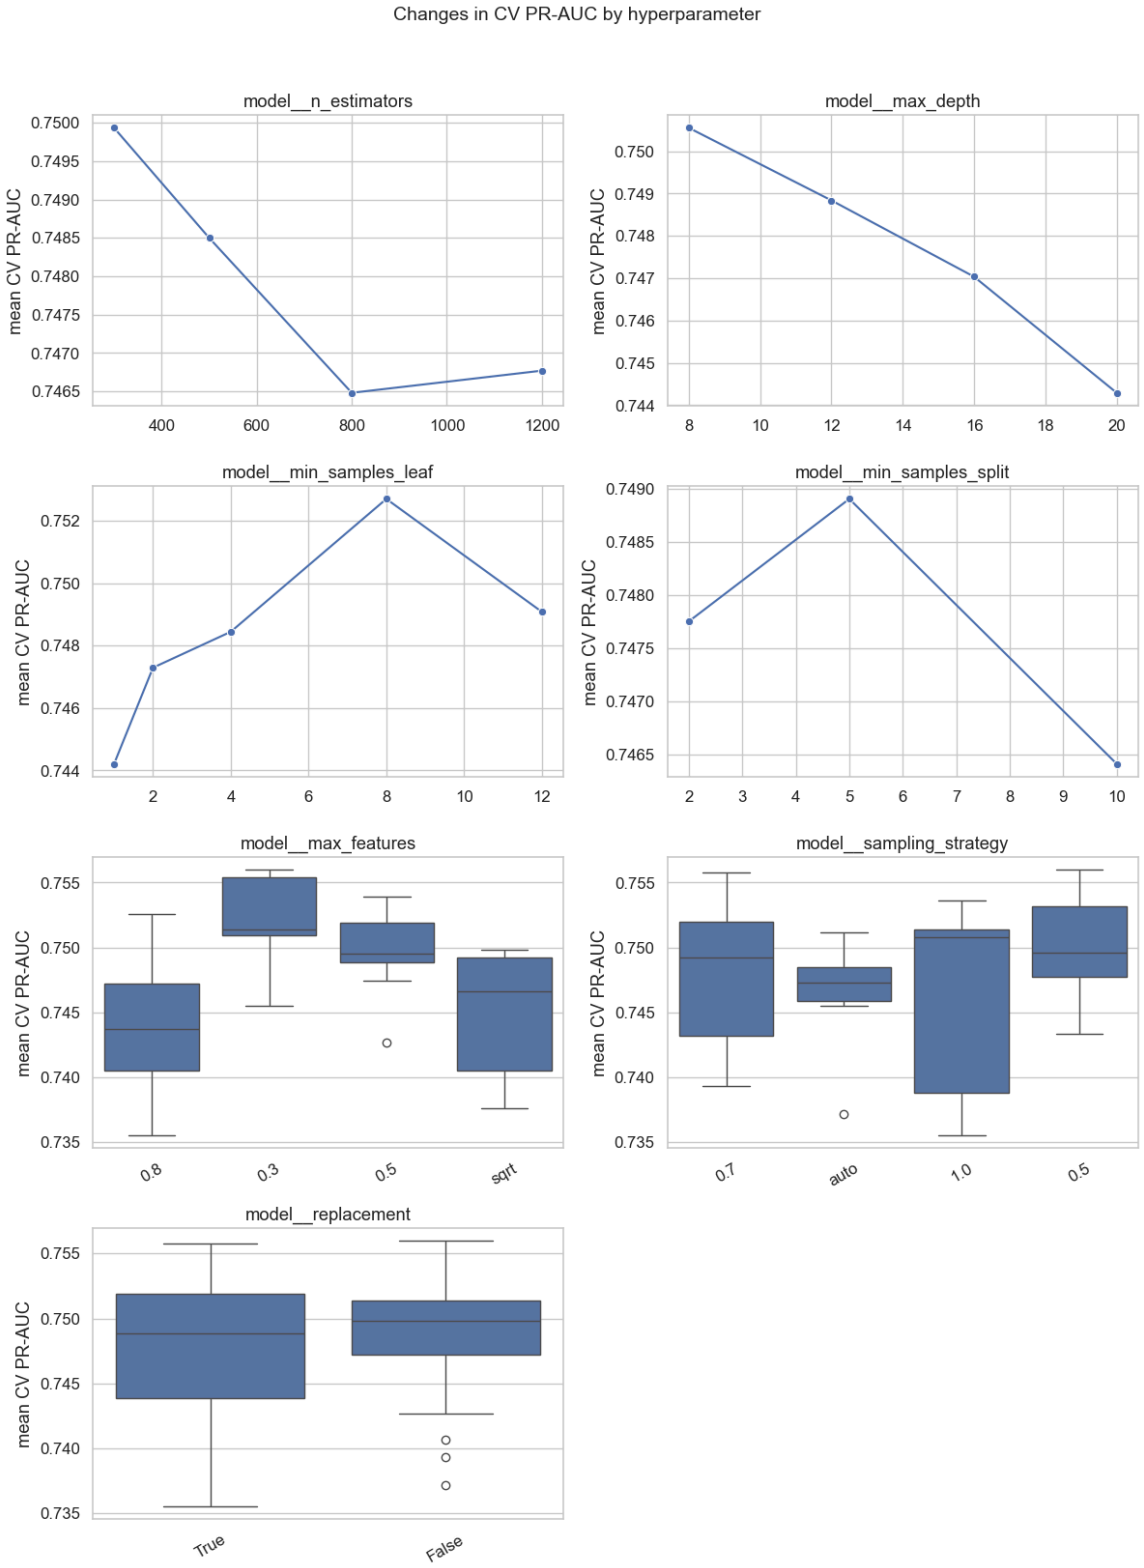

[그림 4-1] PR-AUC 탐색 과정에서의 `n_estimators`, `max_depth`, `min_samples_leaf` 등 주요 하이퍼파라미터 값에 따른 평균 CV PR-AUC 변화 그래프

4.2 최종 PR-AUC Best 파라미터 및 성능

```
Best CV PR-AUC: 0.7559602666233075

Best params:
{
  "model__sampling_strategy": 0.5,
  "model__replacement": false,
  "model__n_estimators": 300,
  "model__min_samples_split": 5,
  "model__min_samples_leaf": 1,
  "model__max_features": 0.3,
  "model__max_depth": 8
}

TEST PR-AUC : 0.7466332225549133
TEST ROC-AUC: 0.9302589663454292
```

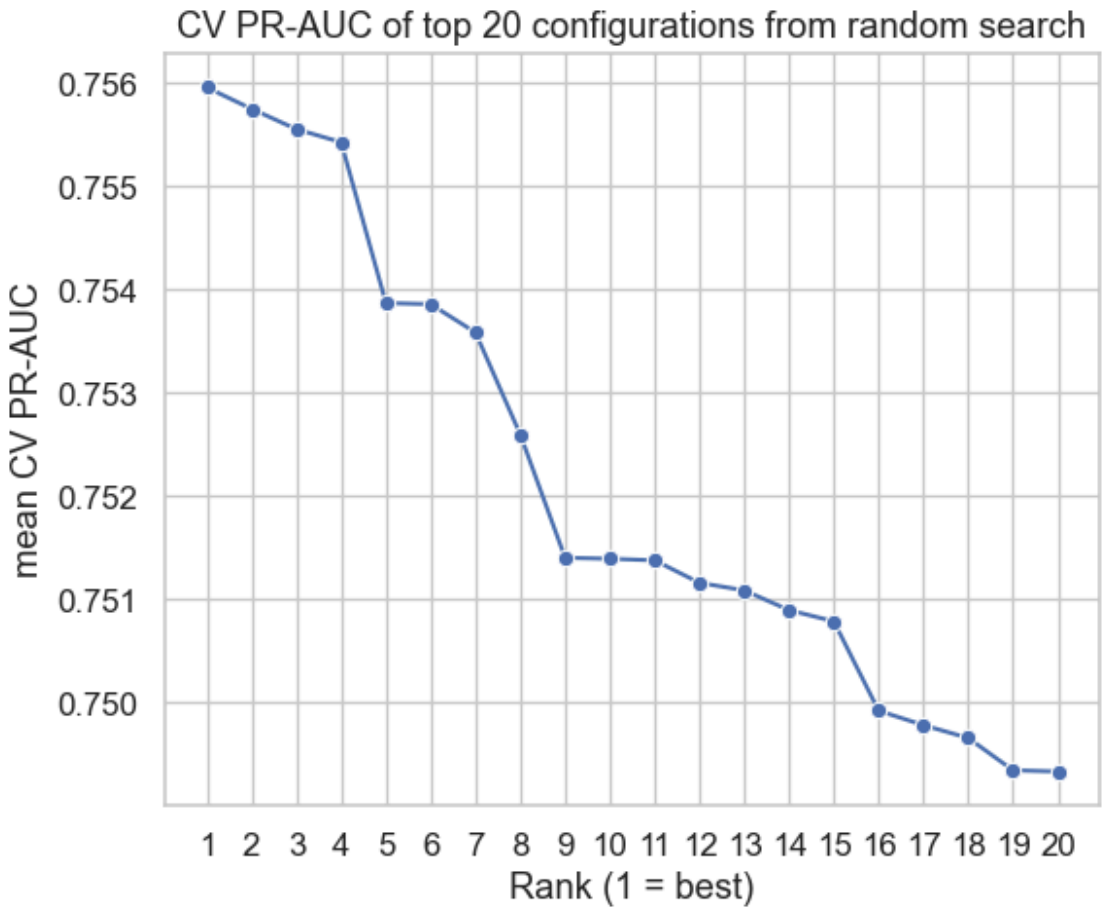

[그림 4-2] PR-AUC 기준 상위 20개 하이퍼파라미터 조합의 CV PR-AUC 랭킹 플롯

- **해석**
  - `n_estimators = 300` : 충분히 많은 트리로 복잡한 패턴을 포착하면서도 학습/예측 시간은 과도하지 않게 유지
  - `max_depth = 8` , `min_samples_split = 5` : 적절한 깊이와 분할 조건으로 과적합 방지
  - `min_samples_leaf = 1` : 리프 노드 최소 샘플 수를 1로 허용해 미세한 패턴까지 포착
  - `max_features = 0.3` : 각 노드에서 전체 feature의 30%만 사용 → 트리 간 다양성 확보
  - `sampling_strategy = 0.5` : 각 트리 학습 시 소수 클래스 비율을 인위적으로 높여, 구매(1) 패턴이 충분히 반영되도록 조절

이 모델은 **PR-AUC 기준으로 최적화된 모델**이며, `best_pr_auc_balancedrf.joblib` 으로 저장하여 이후 분석/데모에서 재사용한다.

추가로 본 모델은 Streamlit 앱에서 "구매 확률(%)"을 직접 제공하기 위해, 학습된 BRF 파이프라인 위에 Calibration 레이어를 적용하여 저장하였다.

- base 파이프라인: 전처리 + BRF (train으로 학습)
- calibrated 모델: base 파이프라인 출력 확률을 calib 데이터로 보정

최종 artifact는 `best_pr_auc_balancedrf.joblib` 로 저장되며, 서빙 시에는 보정된 확률 (`predict_proba`)을 사용한다.

---

5. F1 Score 기반 하이퍼파라미터 및 Threshold 탐색

5.1 탐색 절차

F1 최적화는 다음 구조로 진행하였다.

1. **하이퍼파라미터 그리드 정의**

```
n_estimators      = 1200 (고정)
max_depth         ∈ {None, 8, 12, 16}
min_samples_leaf  ∈ {1, 2, 4, 8}
max_features      ∈ {"sqrt", 0.5, 0.8}
min_samples_split = 2 (고정)
sampling_strategy = "auto"
replacement       = False
```

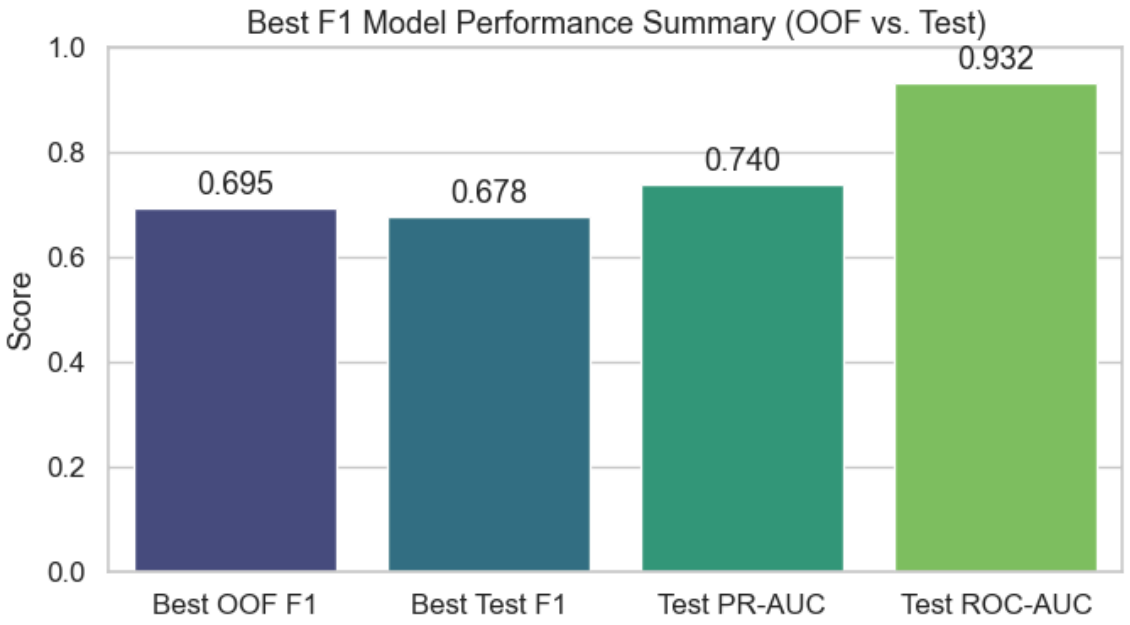

[그림 5-1] F1 최적화 모델의 OOF F1, Test F1, Test PR-AUC, Test ROC-AUC 요약 막대그래프

2. **Out-of-Fold(OOF) 예측 기반 threshold 탐색**
   - StratifiedKFold(5-fold)를 사용하여 각 fold의 검증셋 예측확률을 수집
   - 전체 OOF 예측에 대해 `precision_recall_curve`를 계산
   - threshold별 F1 값을 계산한 뒤, **F1이 최대가 되는 threshold를 선택**
   - 이 로직을 `best_f1_threshold()` 함수로 구현
3. **각 조합별 Test 성능 평가**
   - 위에서 찾은 threshold를 사용해 train 전체로 재학습
   - Test셋에서 F1, PR-AUC, ROC-AUC 계산
   - **Test F1이 가장 높은 조합을 최종 Best F1 모델로 선정**

5.2 최종 Best F1 설정 및 성능

최고 Test F1을 달성한 설정과 성능은 아래와 같다.

```
=== BEST CONFIG (by TEST F1) ===
{
  "params": {
    "n_estimators": 1200,
    "max_depth": None,
    "min_samples_leaf": 8,
    "min_samples_split": 2,
```

```
    "max_features": 0.5,
    "sampling_strategy": "auto",
    "replacement": False
  },
  "thr": 0.7412374222999228,
  "oof_f1": 0.6995734308343593,
  "test_f1": 0.6740467404674046,
  "test_pr_auc": 0.7415823565968093,
  "test_roc_auc": 0.9319585271979982
}
```


- **하이퍼파라미터 해석**
  - `n_estimators = 1200`

    → 트리 수를 충분히 많이 두어 안정적인 앙상블 형성
  - `max_depth = None` , `min_samples_leaf = 8`

    → 최대 깊이는 제한하지 않지만, 리프 최소 샘플 수를 8로 설정하여 지나치게 복잡한 분할을 방지하고 **일반화 성능을 확보**
  - `max_features = 0.5`

    → 각 노드 분할 시 전체 feature의 절반을 사용하여 다양성과 성능 균형을 맞춤
  - `sampling_strategy = "auto"`

    → 불균형 비율을 자동으로 조정하는 라이브러리 기본 전략 사용

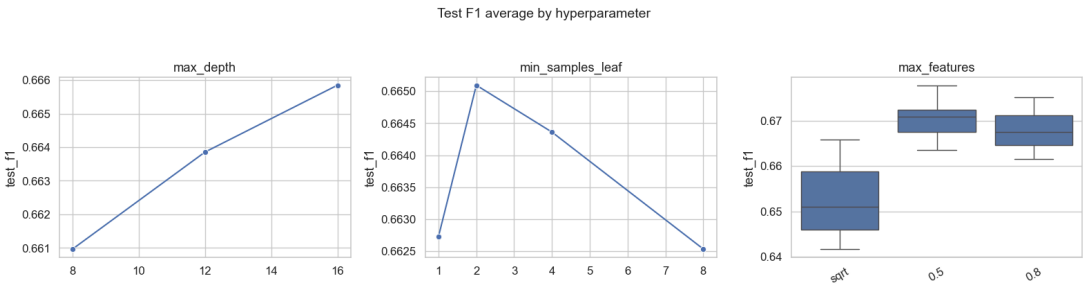

[그림 5-2] F1 최적화 과정에서 `max_depth` , `min_samples_leaf` , `max_features` 에 따른 Test F1 평균 변화 그래프

- **성능 요약**

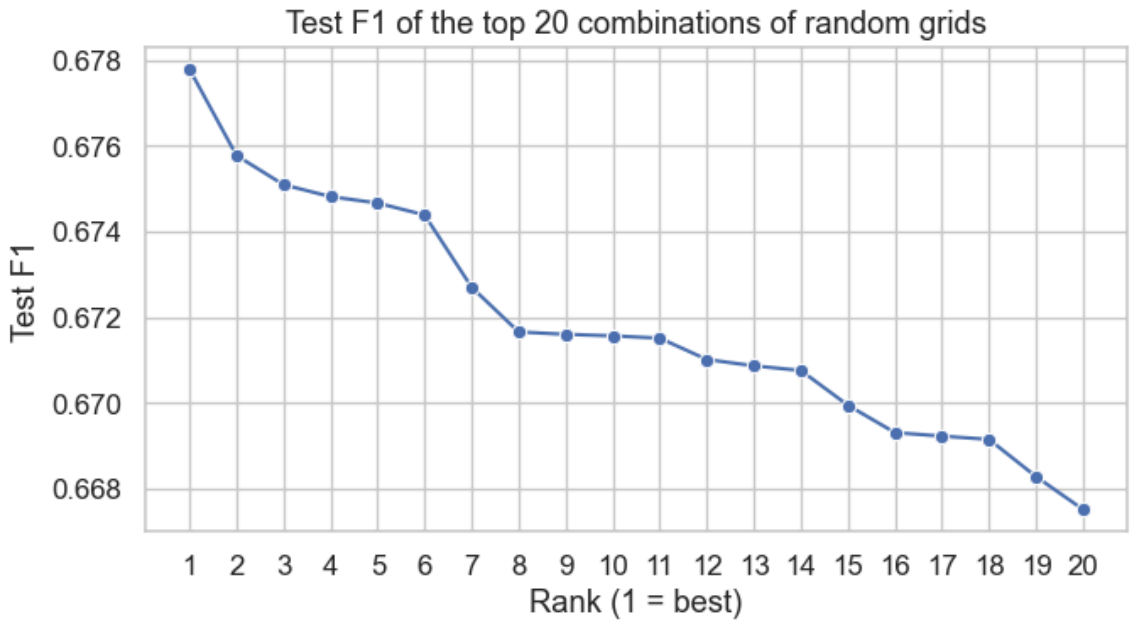

[그림 5-3] F1 기준 상위 20개 하이퍼파라미터 조합의 Test F1 랭킹 플롯

- OOF F1: 약 **0.700**
- Test F1: 약 **0.674**
- Test PR-AUC: 약 **0.742**
- Test ROC-AUC: 약 **0.932**

OOF와 Test F1 간 차이가 크지 않으며, 전체적인 분류 성능도 PR-AUC 모델과 유사한 수준이다.

Out-of-Fold 예측을 이용해 F1이 최대가 되는 threshold를 탐색한 결과, 약 0.74 부근에서 최댓값을 기록하여 이를 최종 운영 기준 threshold로 사용하였다.

---

6. 결론 및 향후 계획

6.1 결론

- **모델 측면**
  - Balanced Random Forest 기반으로
    - PR-AUC 최적화 모델: Test PR-AUC 약 0.747, ROC-AUC 약 0.930
    - F1 최적화 모델: Test F1 약 0.674, PR-AUC 약 0.742, ROC-AUC 약 0.932
  - 불균형 데이터에서도 높은 성능과 안정성을 확보하였다.
- **운영 측면**

    - PR-AUC 모델은 **분석/연구/리포트용 기준 모델**로 활용
    - F1 모델은 **임계값(threshold)을 포함한 실무형 모델**로, 쿠폰/푸시 등 실제 액션을 트리거하는데 사용 가능
- **구조 측면**
    - Adapter + Service 레이어를 도입함으로써
        - 모델 변경/추가에 대한 유연성
        - 다양한 앱/분석 코드에서의 재사용성을 확보하였다.

6.2 향후 계획

- 실제 서비스 로그와 결합한 **도메인 특화 재학습**
- SHAP 등의 기법 도입을 통한 **정량적인 Feature 중요도 및 기여도 시각화**
- 채널/디바이스/지역별 세분화 모델 또는 가중치 조정
- A/B 테스트를 통한 “모델 기반 캠페인 vs 기존 캠페인” 성과 비교
- 더 다양한 페르소나 시나리오를 추가하여, 비즈니스/교육 현장에서의 활용도 확대
